



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н. Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н. Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика, искусственный интеллект и системы управления»

КАФЕДРА ИУ-1 «Системы автоматического управления»

ОТЧЕТ
по лабораторной работе №.2

Дисциплина: Эргатические системы

Студент ИУ1И-41М
(Группа)

31 / 03 /2026
(Подпись, дата)

Чжан Хаотянь
(И.О. Фамилия)

Преподаватель

/ /2026
(Подпись, дата)

Кучин А. С.
(И.О. Фамилия)

2026 г.

1. Цель работы


Цель данного эксперимента — решить задачу бинарной классификации (т.е. прогнозирования состояния здоровья пациента — `Healthy_Status`) в анализе биомедицинских сигналов путем обработки и анализа реальных наборов данных признаков электрокардиограммы (ЭКГ).

Ссылка на репозиторий Git:

<https://github.com/youbadbad2agt/Haotian-Zhang/tree/Machinelearning>

2. Экспериментальная процедура и анализ результатов

ШАГ 1: Анализ уменьшения размерности пространства признаков и топологическая визуализация (на основе диаграмм PCA и t-SNE)



После нормализации многомерной матрицы признаков электрокардиограммы (ЭКГ) до нулевого среднего значения и единичной дисперсии в эксперименте использовались алгоритмы линейного уменьшения размерности (PCA) и нелинейного обучения на многообразиях (t-SNE) для двумерного проекционного анализа.

Анализ главных компонент (PCA): Проекционный график PCA слева показывает, что данные не имеют очевидной структуры в низкоразмерном линейном пространстве. Подавляющее большинство образцов сильно кластеризованы в локальных областях, с очень небольшим количеством выбросов. Это указывает на отсутствие простых линейно разделимых границ в

исходном пространстве признаков, и традиционные линейные классификаторы (такие как логистическая регрессия), вероятно, будут плохо работать на этом наборе данных.

t-распределенное случайное встраивание окрестностей (t-SNE): Топологический график t-SNE справа успешно демонстрирует чрезвычайно сложную нелинейную структуру многообразия внутри данных, представляющую множество нерегулярных микрокластеров. Однако точки выборки, представляющие здоровые (1, зеленый) и нездоровые (0, синий) образцы, сильно связаны и переплетены внутри каждого кластера. [Заключение этого абзаца] Это сильное явление «перекрывания признаков» указывает на то, что набор данных ЭКГ имеет чрезвычайно высокую сложность нелинейной классификации, и необходимо использовать нелинейные алгоритмы машинного обучения с возможностями высокоразмерного отображения признаков или сложными древовидными структурами для моделирования.

ШАГ 2: Результаты автоматического построения модели и оптимизации гиперпараметров


```
2.5s = Training runtime
0.01s = Validation runtime
Fitting model: XGBoost ... Training model for up to 110.43s of the 110.43s of remaining time.
0.702 = Validation score (f1)
0.9s = Training runtime
0.0s = Validation runtime
Fitting model: NeuralNetTorch ... Training model for up to 109.51s of the 109.51s of remaining time.
0.7306 = Validation score (f1)
14.91s = Training runtime
0.01s = Validation runtime
Fitting model: LightGBMLarge ... Training model for up to 94.58s of the 94.58s of remaining time.
0.6224 = Validation score (f1)
1.66s = Training runtime
0.0s = Validation runtime
Fitting model: WeightedEnsemble_L2 ... Training model for up to 119.95s of the 92.88s of remaining time.
0.75 = Validation score (f1)
1.86s = Training runtime
0.0s = Validation runtime
AutoGluon training complete, total runtime = 29.01s ... Best model: "WeightedEnsemble_L2"
TabularPredictor saved. To load, use: predictor = TabularPredictor.load("AutogluonModels\ag-20260430_165002\")
```

 Оптимальная модель (выбрана AutoML): WeightedEnsemble_L2

В эксперименте была представлена платформа AutoGluon для сквозного моделирования AutoML. На основе выходных данных: Глобально оптимальная модель: WeightedEnsemble_L2 (взвешенная ансамблевая модель уровня L2).

В условиях сложных нелинейных распределений данных, выявленных с помощью t-SNE, использование одного базового алгоритма обучения (например, одного дерева решений или базового KNN) перестало быть эффективным для аппроксимации сложных границ принятия решений. В конечном итоге, движок AutoML отказался от использования одной модели, выбрав вместо этого двухуровневое взвешенное объединение/ансамблирование нескольких разнородных мощных алгоритмов (таких как XGBoost, LightGBM, CatBoost и др.). Эта парадигма ансамблевого обучения эффективно интегрирует локальные преимущества представления различных алгоритмов, значительно улучшая общую способность системы к аппроксимации и верхний предел обобщения.

ШАГ 3: Оценка обобщающей способности модели и анализ матрицы ошибок (на основе матрицы ошибок и F1-меры)



На независимо отобранном тестовом наборе оптимальный классификатор, `WeightedEnsemble_L2`, достиг общего показателя эффективности F1-меры = 0,6396. Используя тепловую карту матрицы ошибок, мы можем провести микроанализ этого показателя:

Истинно отрицательные результаты (TN = 715): Модель правильно идентифицировала 715 образцов, относящихся к категории «нездоровые», демонстрируя чрезвычайно высокую специфичность.

Истинно положительные результаты (TP = 134): Модель правильно идентифицировала 134 здоровых образца.

Ложноположительные результаты (FP = 93): Это ошибка первого типа; 93 образца, которые на самом деле были «нездоровыми», были ошибочно классифицированы моделью как «здоровые».

Ложноотрицательный результат (FN = 58): Это ошибка второго типа, при которой 58 первоначально «здоровых» образцов ошибочно классифицируются моделью как «нездоровые».

4. Заключение

Матрица ошибок показывает, что это типичный медицинский набор данных с дисбалансом классов или искаженными априорными вероятностями (размер выборки «Нездоровые» значительно превышает размер выборки «Здоровые»).

Модель демонстрирует подавляющую точность в прогнозировании класса большинства («Нездоровые»).

Для класса меньшинства («Здоровые») показатель полноты модели ($\text{Recall} = 134 / (134+58) \approx 0,698$) является приемлемым, указывая на то, что она охватывает почти 70% признаков здоровья; однако ее точность ($\text{Precision} = 134 / (134+93) \approx 0,59$) несколько снижена.

Общая оценка: Учитывая высокое перекрытие меток классов, показатель F1, равный 0,6396, объективно отражает, что модель успешно извлекла статистически значимые отличительные закономерности, значительно превосходящие уровень случайного угадывания, демонстрируя эффективность этой ансамблевой стратегии AutoML в классификации сложных биомедицинских сигналов.