



Министерство науки и высшего образования Российской Федерации  
Федеральное государственное бюджетное образовательное учреждение  
высшего образования  
«Московский государственный технический университет  
имени Н. Э. Баумана  
(национальный исследовательский университет)»  
(МГТУ им. Н. Э. Баумана)

---

ФАКУЛЬТЕТ      ИУ «Информатика, искусственный интеллект и системы управления»

---

КАФЕДРА      ИУ-1 «Системы автоматического управления»

---

**ОТЧЕТ**  
**по лабораторной работе №.4**

**Дисциплина:** Эргатические системы

Студент      ИУ1И-41М  
(Группа)

31 / 03 /2026  
(Подпись, дата)

Чжан Хаотянь  
(И.О. Фамилия)

Преподаватель

/ /2026  
(Подпись, дата)

Кучин А. С.  
(И.О. Фамилия)

2026 г.

## 1. Цель работы

Цель данного эксперимента — разработка и проверка системы классификации электроэнцефалограмм (ЭЭГ) на основе глубокого обучения для автоматической идентификации эпилептических припадков. Одномерные временные ряды ЭЭГ преобразуются в двумерные частотно-временные изображения с помощью непрерывного вейвлет-преобразования (CWT), а признаки извлекаются с помощью сверточной нейронной сети (CNN) для бинарной классификации (норма против припадка).

Ссылка на репозиторий Git:

<https://github.com/youbadbad2agt/Haotian-Zhang/tree/Machinelearning>


## 2. Экспериментальная процедура и анализ результатов

### 1. Методика и подготовка данных

Для строгой оценки истинной обобщающей способности модели и полного исключения утечки данных временных рядов в эксперименте использовалась стратегия физического разделения данных на основе записей:


**Источник данных:** база данных ЭЭГ головы PhysioNet CHB-MIT (случай chb08).

**Формирование обучающей выборки:** Использование исключительно записи chb08\_02.edf. С помощью 3-секундного окна было извлечено по 50 сегментов в течение иктальной фазы (2670-2841 секунд) и нормальной фазы.



**Формирование валидационной выборки:** Использование исключительно записи chb08\_13.edf, которая не использовалась в обучении. Снова с помощью

3-секундного окна было извлечено по 50 сегментов в течение иктальной фазы (2417-2577 секунд) и нормальной фазы.




**Предварительная обработка данных:** были выбраны каналы FP1-F7, и для генерации псевдоцветного изображения Jet размером 224x224 пикселя без координатных осей было применено преобразование Морле (шкала 1-128).

**Архитектура сети:** была построена полносвязная выходная сверточная нейронная сеть с 3 сверточными слоями пулинга (32-64-128 каналов) и Dropout (0,5), обученная в течение 15 эпох с использованием оптимизатора Adam и функции потерь бинарной кросс-энтропии.

## 2. Результаты и анализ

### 2.1 Анализ кривых обучения



**Точность:** Точность на обучающем наборе (синяя линия) быстро достигает 100% (1,0) примерно к 5-й эпохе. Точность на валидационном наборе (красная линия) изначально высока, но затем сильно колеблется, в конечном итоге стабилизируясь в диапазоне 70–80%.


**Функция потерь:** Это наиболее важный показатель. Потери на обучающем наборе (синяя линия) неуклонно снижаются, приближаясь к 0. Однако потери на

валидационном наборе (красная линия) начинают устойчиво и значительно расти после 4-й эпохи (взлетая с 0,5 до более чем 3,0).

Вывод: Модель демонстрирует сильное переобучение. Сеть идеально запоминает все детали обучающего набора (chb08\_02.edf) (включая специфический фоновый шум), но распределение вероятностей на выходе показывает огромное отклонение при работе с совершенно новым валидационным набором (chb08\_13.edf).

## 2.2 Анализ матрицы ошибок

Матрица ошибок на валидационной выборке (Запись 1)



В проверочном наборе из 100 образцов результаты классификации модели были следующими:

Истинно положительные (предполагаемый приступ и фактический приступ): 49 случаев  
Ложноотрицательные (предполагаемый нормальный результат, но фактический приступ, пропущенный диагноз): 1 случай

Истинно отрицательные (предполагаемый нормальный результат и фактический нормальный результат): 29 случаев

Ложноположительные (предполагаемый приступ, но фактический нормальный результат, ошибочный диагноз): 21 случай

### Вывод:

Чрезвычайно высокая чувствительность (чувствительность/полнота = 98%): Модель очень чувствительна к обнаружению «характеристик приступа», пропуская практически все реальные эпилептические приступы.

Низкая специфичность (специфичность = 58%): Модель

продемонстрировала серьезную «ложноположительную предвзятость». Она ошибочно классифицировала почти половину (21/50) нормальных ЭЭГ как эпилепсию. Это подтверждает аномалию на кривой потерь: модель склонна давать консервативные и неверные определения «захвата» при работе с неизвестными данными.

### 3. Заключение

В ходе данного эксперимента была успешно разработана, реализована и протестирована система автоматического обнаружения эпилептических приступов на основе анализа временных рядов электроэнцефалограммы (ЭЭГ). Построенный пайплайн объединил методы цифровой обработки сигналов (непрерывное вейвлет-преобразование, CWT) и глубокого обучения (сверточные нейронные сети, CNN) для бинарной классификации состояний «норма» и «приступ».

#### **Ключевые выводы по результатам работы:**

**Важность методологии валидации:** Главным достижением эксперимента стал отказ от стандартного случайного разделения данных в пользу строгой поканальной и файловой изоляции (Record-wise split). Обучение модели на записи chb08\_02.edf и ее независимое тестирование на chb08\_13.edf позволило избежать эффекта «утечки данных» (data leakage) и получить объективную картину работы сети.

**Высокая чувствительность модели:** Разработанная архитектура CNN продемонстрировала отличную способность извлекать частотно-временные паттерны приступов на вейвлет-изображениях. Модель показала крайне низкий процент ложноотрицательных результатов (пропусков приступов).

**Проблема переобучения (Overfitting) и гипердиагностики:** Графики функции потерь и матрица ошибок выявили уязвимость модели к переобучению. Сеть слишком хорошо «запомнила» специфический фоновый шум обучающего файла, из-за чего на новых данных (валидационная запись) стала выдавать большое количество ложноположительных результатов (ложных тревог).

**Перспективы и дальнейшие шаги:** Полученные результаты наглядно доказывают, что для задач медицинской диагностики недостаточно использовать фрагменты одной записи. Для создания надежной клинической модели, устойчивой к индивидуальным особенностям пациентов и фоновым артефактам, в дальнейшем необходимо:

**Масштабировать набор данных:** включить в обучающую выборку записи множества разных пациентов (cross-patient training).

**Применить аугментацию:** использовать метод перекрывающихся скользящих окон (sliding window) для искусственного увеличения объема данных.

**Оптимизировать архитектуру:** внедрить методы сильной регуляризации (L2-регуляризация, увеличение Dropout) или использовать методы трансферного обучения (Transfer Learning) на базе легковесных предобученных моделей (например, MobileNet).

Эксперимент полностью достиг своей цели, не только решив задачу классификации, но и наглядно продемонстрировав критическую важность правильной валидации при работе со сложными медицинскими временными рядами.