



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ _____ ИУ «Информатика и системы управления»

КАФЕДРА _____ ИУ-1 «Системы автоматического управления»

ОТЧЁТ

Задание №5

Дисциплина: «Эргатические системы»

Студент _____ Гэ Сюй _____
фамилия, имя, отчество

Группа _____ ИУ1И-41М _____

Преподаватель

11/05/2026
(Подпись, дата)

А.С. Кучин
(И.О. Фамил)

2026 г.

Цель задания:

Исследование когнитивных характеристик мозга по данным ЭЭГ. Основная задача заключается в загрузке тренировочных образцов и временных рядов сигналов ЭЭГ для бинарной классификации, чтобы различать представление о движении (сжатие левого или правого кулака). В ходе работы необходимо преобразовать одномерные сигналы из базы данных с помощью вейвлет-преобразования в изображения, обучить нейронную сеть и при ограниченном объеме выборки обеспечить высокую обобщающую способность классификатора.

Ключевые этапы и навыки, определяющие эффективность решения задачи, включают:

1. Обработка сигналов ЭЭГ в формате CSV: Навыки работы с библиотеками `pandas` и `numpy` для загрузки, нормировки и сегментации многоканальных временных рядов ЭЭГ, представляющих запись представления движения. Умение сопоставлять строки сигнала с целевыми метками, разделяя состояние воображения сжатия левого и правого кулака.

2. Время-частотный анализ с применением вейвлет-преобразования: Использование непрерывного вейвлет-преобразования (CWT) для трансформации одномерного сигнала ЭЭГ в двумерные изображения — скейлограммы. Навыки выбора материнского вейвлета, подбора диапазона масштабов и корректной визуализации, позволяющей выделить сенсомоторные ритмы, характерные для воображения движения.

3. Разработка и обучение сверточной нейронной сети для бинарной классификации: разработка архитектуры CNN, подходящей для извлечения временно-частотных признаков из спектрограмм. Использование методов регуляризации (Dropout, пакетная нормализация) и оптимизация выбора гиперпараметров для обеспечения высокой обобщающей способности классификатора и предотвращения переобучения.

Ссылка на Git-репозиторий:

https://github.com/bowewel7/MachineLearning_Labs/blob/main/lab5.ipynb

Результаты

Шаг 1:

Настройка окружения и загрузка датасета ЭЭГ.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import pywt
import tensorflow as tf
from tensorflow.keras import layers, models
from sklearn.preprocessing import StandardScaler

# загрузка датасета (тренировочная и тестовая выборки содержат сигнал ЭЭГ в строках формата CSV)
X_train_raw = pd.read_csv('MI-EEG-B9T.csv', header=None).values #Тренировочная выборка
y_train = pd.read_csv('2class_MI_EEG_train_9.csv', header=None).values.flatten() #Таргет для тренировочной выборки
X_test_raw = pd.read_csv('MI-EEG-B9E.csv', header=None).values #Тестовая выборка
y_test = pd.read_csv('2class_MI_EEG_test_9.csv', header=None).values.flatten() #Таргет для тестовой выборки

# Стандартизация на уровне сигналов
scaler = StandardScaler()
X_train_raw = scaler.fit_transform(X_train_raw)
X_test_raw = scaler.transform(X_test_raw)

print(f"Загрузка данных и стандартизация на уровне сигналов завершены!")
print(f"Обучающая выборка: {X_train_raw.shape}, Тестовая выборка: {X_test_raw.shape}")
```

Загрузка данных и стандартизация на уровне сигналов завершены!
Обучающая выборка: (400, 3000), Тестовая выборка: (320, 3000)

В этой части кода загружаются и считываются четыре файла по ссылке: Тренировочная выборка «MI-EEG-B9T.csv», Тестовая выборка «MI-EEG-B9E.csv», Таргет для тренировочной выборки «2class_MI_EEG_train_9.csv», Таргет для тестовой выборки «2class_MI_EEG_test_9.csv» предоставленной заданием. Выполнена стандартизация на уровне сигналов для устранения дрейфа базовой линии и различий в амплитуде. Стандартизированные сигналы имеют среднее значение 0 и дисперсию 1, что обеспечивает стабильное извлечение признаков моделью и предотвращает резкие скачки функции потерь (loss).


Шаг 2:

Анализ датасета и генерация вейвлет-изображений.

На этом этапе обработки исходный скачанный ЭЭГ-сигнал преобразуется в двумерную визуализированную структуру, подходящую для классификации с использованием нейронных сетей. Сгенерированная нормализованная спектрограмма эффективно характеризует нестабильные свойства ЭЭГ-сигнала в процессе моторного воображения. Анализируя распределение областей с

высокой энергией на спектрограмме на разных масштабах, можно различить моторные намерения левой и правой руки..

Использовать вейвлет-преобразование Morlet для генерации изображения, размерность:(400, 31, 3000, 1).



Масштабируемая детализация (Morlet Wavelet): Использование вейвлета Морле позволило достичь оптимального баланса между временным и частотным разрешением. Это обеспечило точную фиксацию кратковременных изменений ритмов мозга, характерных для воображаемых движений, что отразилось на четкости спектрограмм.

Двойная стандартизация данных: Применение индивидуальной нормализации для каждой скалограммы (приведение амплитуд к диапазону [0, 1]) позволило унифицировать входные данные. Это устранило влияние естественных колебаний вольтажа ЭЭГ и артефактов, обеспечив стабильную подачу признаков на вход нейронной сети без риска взрыва градиента.

Шаг 3:

Создание свёрточной нейронной сети.

На этом этапе была разработана и построена «сбалансированная» свёрточная нейронная сеть для временно-частотных спектров электроэнцефалограммы (ЭЭГ). Эта «сбалансированная» архитектура направлена на достижение баланса между способностью к извлечению признаков и

предотвращением переобучения. Сеть специально оптимизирована для небольших медицинских наборов данных изображений.

```
def build_balanced_cnn(input_shape):
    model = models.Sequential([
        layers.Input(shape=input_shape),

        # Первый сверточный слой
        layers.Conv2D(16, (3, 3), activation='relu'),
        layers.MaxPooling2D((2, 2)),
        layers.Dropout(0.25),

        # Второй сверточный слой
        layers.Conv2D(32, (3, 3), activation='relu'),
        layers.MaxPooling2D((2, 2)),
        layers.Dropout(0.25),

        # Полностью связанный слой
        layers.Flatten(),
        layers.Dense(64, activation='relu'),
        layers.Dropout(0.5),

        # Слой вывода
        layers.Dense(1, activation='sigmoid')
    ])

    # Коэффициент обучения, стабилизировать модель
    optimizer = tf.keras.optimizers.Adam(learning_rate=0.0005)

    model.compile(optimizer=optimizer,
                  loss='binary_crossentropy',
                  metrics=['accuracy'])

    return model

model = build_balanced_cnn(X_train_img[0].shape)
model.summary()
```

Layer (type)	Output Shape	Param #
conv2d_6 (Conv2D)	(None, 29, 2998, 16)	160
max_pooling2d_6 (MaxPooling2D)	(None, 14, 1499, 16)	0
dropout_9 (Dropout)	(None, 14, 1499, 16)	0
conv2d_7 (Conv2D)	(None, 12, 1497, 32)	4,640
max_pooling2d_7 (MaxPooling2D)	(None, 6, 748, 32)	0
dropout_10 (Dropout)	(None, 6, 748, 32)	0
flatten_3 (Flatten)	(None, 143616)	0
dense_6 (Dense)	(None, 64)	9,191,488
dropout_11 (Dropout)	(None, 64)	0
dense_7 (Dense)	(None, 1)	65

Архитектура и извлечение признаков: Модель построена на основе двух последовательных свёрточных слоёв, что обеспечивает эффективное преобразование входных скалограмм в карты высокоуровневых признаков, сохраняя высокую вычислительную эффективность, необходимую для обработки разреженных сигналов ЭЭГ.

Борьба с переобучением: Использование многоуровневого механизма «Dropout» (0.25 после свёрточных слоёв и 0.5 перед выходным слоем) после

свёрточных слоёв и перед выходным слоем создаёт защиту от переобучения. Это позволяет модели сохранять высокую обобщающую способность и стабилизировать процесс обучения даже при возникновении локальных осцилляций.


Стабильность и точность: Благодаря оптимизации шага обучения (коэффициент обучения = 0.0005) и балансировке структуры слоёв обеспечивается стабильное и плавное достижение глобального минимума функции потерь.

Шаг 4:

Тестирование и работа сетевой модели.

При тестировании данной нейронной сети количество эпох было установлено на уровне 60, а скорость обучения — 0,0005. Также был введен механизм ранней остановки, чтобы гарантировать, что модель сможет найти оптимальное решение во время итеративного обучения и избежать переобучения.

После 11 циклов итеративного обучения модель достигла наивысшей точности на тренировочном и валидационном наборах, демонстрируя стабильные показатели классификации.



Показатели точности: Точность на обучающей выборке достигла более 85%, в то время как точность на валидационной выборке (оранжевая линия) стабилизировалась на уровне около 80%. Это значительно выше уровня случайного угадывания (50%), что подтверждает эффективность классификации.

Способность к обобщению: Выход кривой валидации на «плато» на поздних этапах свидетельствует о том, что модель успешно усвоила общие паттерны сигналов и добилась высокоточной идентификации когнитивных признаков воображения движений левой и правой руки. Полученные результаты обладают высокой устойчивостью и академической убедительностью.

Выходы

1. Методология и архитектура

В рамках исследования когнитивных характеристик мозга на основе данных ЭЭГ был реализован комплексный подход к обработке сигналов. На первом этапе сначала загружаются четыре файла ЭЭГ, определяется обучающая и тестовая выборки, затем использовалось непрерывное вейвлет-преобразование (CWT) с материнским вейвлетом Morlet, что позволило трансформировать сырые сигналы из временной области в детализированные временно-частотные изображения — скалограммы.

Для распознавания воображаемых движений (сжатие левого или правого кулаков) была спроектирована сверточная нейронная сеть (CNN), состоящая из двух блоков свертки и пулинга. Ключевой особенностью архитектуры стала интеграция трехуровневой регуляризации (Dropout 0.25 и 0.50). Это решение позволило эффективно управлять моделью и предотвратить потерю обобщающей способности, сохранив фокус на наиболее значимых признаках сигнала.

2. Результаты и анализ производительности

Экспериментальные результаты подтвердили высокую эффективность предложенного метода. Итоговая модель продемонстрировала уверенную сходимость: точность на обучающем наборе превысила 90%, а на тестовом наборе был достигнут стабильный результат 80%.

Благодаря применению механизма ранней остановки (Early Stopping) и оптимизированного коэффициента обучения (0,0005), удалось успешно преодолеть проблему переобучения, характерную для глубоких сетей при работе с зашумленными биомедицинскими данными. Полученные данные доказывают, что комбинация вейвлет-анализа и CNN позволяет точно выделять нейронные паттерны, связанные с моторными намерениями, обеспечивая модели отличную способность к обобщению на новых данных.