



Московский государственный технический университет
Факультет ИУ «Информатика и системы управления»
Кафедра ИУ-1 «Системы автоматического управления»

ОТЧЕТ

Лабораторная работа №5

по дисциплине

«Эргатические системы»

Выполнил: Самара Сулейман

Группа: ИУ1И-41М

Аннотация

В работе рассматривается задача классификации моторного воображения по данным электроэнцефалографии. Требуется различать два когнитивных состояния: мысленное представление движения левого кулака и правого кулака. Для решения задачи предложен самостоятельный конвейер обработки данных: автоматический поиск CSV-файлов, построчная нормализация сигналов, преобразование одномерных рядов в вейвлет-изображения и обучение сверточной нейронной сети в среде PyTorch. В отличие от типовой реализации на Keras, в данной версии используется другая архитектура модели, иной способ представления признаков и отдельная валидационная выборка. Фактические метрики и рисунки заполняются после запуска ноутбука на исходных файлах.

1. Введение

Исследование когнитивных характеристик мозга по ЭЭГ является важной задачей интеллектуальных эргатических систем. Сигналы ЭЭГ обладают высокой изменчивостью, поэтому для их анализа применяются методы предобработки, временно-частотные преобразования и модели глубокого обучения. В лабораторной работе рассматривается бинарная классификация моторного воображения на основе набора данных EEG Motor Movement/Imagery Dataset.

2. Постановка задачи

Цель работы состоит в построении классификатора, который по сигналу ЭЭГ определяет, какому из двух классов он соответствует: мысленному движению левого кулака или мысленному движению правого кулака. Для достижения цели необходимо загрузить тренировочные и тестовые CSV-файлы, сформировать информативное представление сигнала, обучить сверточную нейронную сеть, сохранить лучшую модель и оценить качество классификации на тестовой выборке.

3. Исходные данные

В работе используются четыре исходных файла: MI-EEG-B9T.csv и MI-EEG-B9E.csv с сигналами ЭЭГ, а также class_MI_EEG_train_9.csv и class_MI_EEG_test_9.csv с метками классов. Каждая строка таблицы сигналов соответствует отдельной реализации ЭЭГ. Для обеспечения воспроизводимости ноутбук автоматически ищет необходимые файлы внутри каталога /kaggle/input.

Файл	Назначение
MI-EEG-B9T.csv	тренировочные сигналы
MI-EEG-B9E.csv	тестовые сигналы
class_MI_EEG_train_9.csv	метки тренировочной выборки
class_MI_EEG_test_9.csv	метки тестовой выборки

4. Предварительная обработка

На первом этапе выполняется загрузка CSV-файлов и проверка размерностей массивов. Далее каждая запись ЭЭГ нормируется отдельно по формуле z-преобразования.

Такой подход устраняет влияние абсолютного масштаба сигнала и позволяет сосредоточиться на форме и локальных особенностях временного ряда. Для визуального контроля в ноутбуке строятся графики исходных нормированных сигналов для представителей обоих классов.

5. Формирование вейвлет-изображений

После нормализации каждый одномерный сигнал преобразуется в двумерное временно-частотное представление. Для этого применяется непрерывное вейвлет-преобразование с `wavelet morl` и набором масштабов от 1 до 48. Перед преобразованием сигнал при необходимости приводится к длине 512 отсчетов методом интерполяции, после чего вычисляется матрица вейвлет-коэффициентов. Полученное изображение нормируется и сохраняется в виде RGB-представления размером 96×96 пикселей.

6. Архитектура нейронной сети

В данной версии решения используется собственная CNN-модель на PyTorch. Архитектура включает три сверточных блока с Batch Normalization, функцией активации ReLU и подвыборкой MaxPool. Далее применяется AdaptiveAvgPool, что позволяет получить компактный вектор признаков, который поступает в полносвязный классификатор. Для обучения используется функция потерь BCEWithLogitsLoss и оптимизатор Adam. Лучшая модель сохраняется по значению ассурасу на валидационной выборке.

7. Организация эксперимента

Тренировочная выборка дополнительно делится на обучающую и валидационную части в стратифицированном режиме. После этого формируются объекты Dataset и DataLoader, обеспечивающие пакетную подачу данных в нейронную сеть. Обучение проводится в течение 12 эпох, а после завершения выполняется тестирование на независимой тестовой выборке. В процессе эксперимента сохраняются история обучения, матрица ошибок, графики потерь и точности, а также итоговый JSON-файл с метриками.

8. Результаты эксперимента

После выполнения ноутбука были получены фактические количественные результаты. Исходные массивы имеют размерности $X_{train_raw} = (400, 3000)$, $X_{test_raw} = (320, 3000)$, а соответствующие векторы меток — $y_{train_raw} = (400,)$ и $y_{test_raw} = (320,)$. Классы в обучающей и тестовой выборках сбалансированы: 200/200 и 160/160 соответственно. После преобразования одномерных сигналов в вейвлет-изображения сформированы массивы $X_{train_img} = (400, 96, 96, 3)$ и $X_{test_img} = (320, 96, 96, 3)$. Для обучения CNN обучающая часть была дополнительно разделена на $train = (320, 96, 96, 3)$, $validation = (80, 96, 96, 3)$ и $test = (320, 96, 96, 3)$.

Показатель	Значение
Train shape	(320, 96, 96, 3)
Validation shape	(80, 96, 96, 3)

Test shape	(320, 96, 96, 3)
Accuracy	0.6469
Precision	0.6715
Recall	0.5750
F1-score	0.6195

На тестовой выборке получены следующие значения: test loss = 0.6861, accuracy = 0.6469, precision = 0.6715, recall = 0.5750, F1-score = 0.6195. Матрица ошибок имеет вид $[[115, 45], [68, 92]]$, что соответствует 115 верно распознанным объектам класса 0 и 92 — класса 1. Ниже приведены иллюстрации исходных сигналов, примеров вейвлет-представлений, кривых обучения и итоговой матрицы ошибок.

Дополнительные количественные характеристики выборки

Показатель	Значение
Размерность X_train_raw	(400, 3000)
Размерность X_test_raw	(320, 3000)
Размерность y_train_raw	(400,)
Размерность y_test_raw	(320,)
Баланс классов train	0: 200, 1: 200
Баланс классов test	0: 160, 1: 160
Размерность X_train_img	(400, 96, 96, 3)
Размерность X_test_img	(320, 96, 96, 3)
Train/Val/Test после split	(320, 96, 96, 3) / (80, 96, 96, 3) / (320, 96, 96, 3)
Матрица ошибок	$[[115, 45], [68, 92]]$




Рисунок 1 — Примеры нормированных исходных сигналов ЭЭГ




Рисунок 2 — Примеры вейвлет-изображений для двух классов





Рисунок 3 — Кривые обучения модели (loss и accuracy)



9. Заключение

В ходе лабораторной работы был реализован полный конвейер классификации моторного воображения по данным ЭЭГ: загрузка исходных CSV-файлов, нормализация сигналов, преобразование одномерных рядов в вейвлет-изображения, обучение сверточной нейронной сети и оценка ее качества на независимой тестовой выборке. Полученные результаты показывают, что модель обеспечивает accuracy 0.6469 и F1-score 0.6195. Матрица ошибок $\begin{bmatrix} 115 & 45 \\ 68 & 92 \end{bmatrix}$ свидетельствует о приемлемой способности модели различать два класса, однако наличие 68 ошибок второго рода указывает на возможность дальнейшего улучшения архитектуры и настройки гиперпараметров.

Список литературы

1. Goldberger A. L. et al. PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals.
2. Mallat S. A Wavelet Tour of Signal Processing. Academic Press.
3. Goodfellow I., Bengio Y., Courville A. Deep Learning. MIT Press.